

Ausarbeitung zur Projektarbeit „Wissenschaftliches Programmieren mit Cuda“

Guanhua Bai, Achim Grolms und Buyu Xiao

Abstract—Dieser Text beschreibt unsere Erfahrungen und Ergebnisse bei der Implementierung des IDR(s) [1] Algorithmus auf CUDA-fähigen Grafikkarten des Herstellers Nvidia mit doppelter Fließkommagenauigkeit im Rahmen einer vierteljährlichen Projektarbeit an der Universität Paderborn im Winter 2009/2010

I. EINLEITUNG

DAS Lösen großer linearer Gleichungssysteme tritt häufig auf im Zusammenhang mit Feldtheoretischen Problemen. Grafikkarten (GPU) mit vielen parallelen Prozessoren sind geeignet als Rechenhardware um die rechnergestützte Lösung dieser LGS zu beschleunigen. Die Hersteller ATI und NVIDIA bieten SDK an speziell für die Entwicklung mit diesem Einsatzzweck. CUDA [2] ist ein API für GPU von Nvidia für die Entwicklung in C und C++.

Matlab bietet zum Einbinden eigenen C-Codes das API 'Mex' an.

II. ARITHMETISCHE OPERATIONEN

A. Operationen

Der iterative Löser IDR(s) [1] besteht aus Operationen [1] der linearen Algebra, im einzelnen in Tabelle I beschrieben.

TABLE I: Im IDR(s) verwendete Operationen

Operation	Zusammenhang	Bemerkung
Addition	$c = a + b$	
Skalarprodukt	$s = a \cdot b$	
Norm	$ a = \sqrt{a \cdot a}$	
Matrix-Vektorprodukt	$c = A_{full} \cdot b$	A_{full} vollbesetzt
Matrix-Vektorprodukt	$c = A_s \cdot b$	A_s dünnbesetzt
Löser nach Gauß	$M \cdot m = c$	Zeile 36 idrs.m [1]

A_s wird im Speicher dargestellt durch das „Sparse Matrix“-Speicherformat aus Matlab. [3]

B. Implementierung der Operationen

Blocks sind Gruppen von Threads die auf einem einzigen Multiprozessor laufen und gemeinsam das schnelle on-chip „shared Memory“ des Multiprozessors nutzen können. [2] Die Operationen sind in doppelter Fließkommagenauigkeit implementiert.

Guanhua Bai, Achim Grolms und Buyu Xiao sind Studenten an der Universität Paderborn im Fachgebiet „Theoretische Elektrotechnik“

1) *Skalarprodukt*: Abb. 1 zeigt schematisch eine Skalarprodukt-Implementierung in CUDA:

Der n te Thread berechnet das Vektorelement $c_n = a_n \cdot b_n$. Die Elemente des Ergebnisvektors c werden zu einem Skalar aufsummiert. Überschreitet die Vektorgöße die maximale Blockgröße 512 iteriert der Thread über mehrere Elemente, oder mehrere Blöcke müssen abgestimmt auf den großen Vektoren arbeiten.

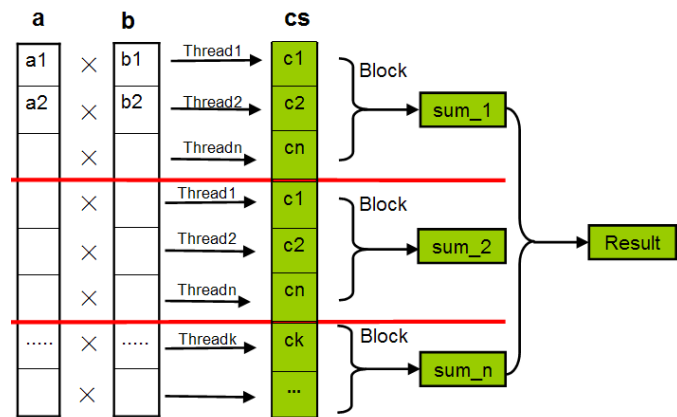


Fig. 1: Skalarprodukt: Multiplikator a , Multiplikand b , (Zwischen-)Ergebnisvektor c_s

2) *Matrix-Vektorprodukt*: Die CUDA-Implementierung zerlegt die Matrix-Vektormultiplikation in einzelne Vektorprodukte. Abb.2 zeigt wie die Teilvektoren von A mit dem Vektor b innerhalb eines Blockes multipliziert werden.




Fig. 2: Matrix-Vektorprodukt: Multiplikator A , Multiplikand b , Produkt c

3) *Matrix-Vektorprodukt mit Sparsematrix*: Als Sparsematrix oder dünnbesetzte Matrix bezeichnet man eine Matrix bei der die Mehrheit der Elemente aus Nullen besteht. Abb.3 zeigt ein einfaches Beispiel. Aus Platzspargründen nutzt Matlab ein spezielles Memorylayout [3] mit dem nur die nonzero-Elemente im Speicher gehalten werden.

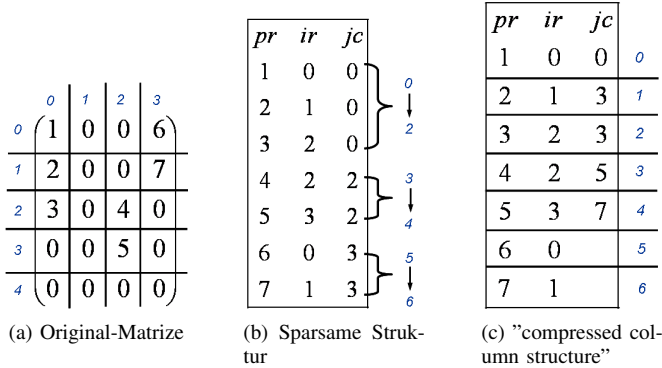
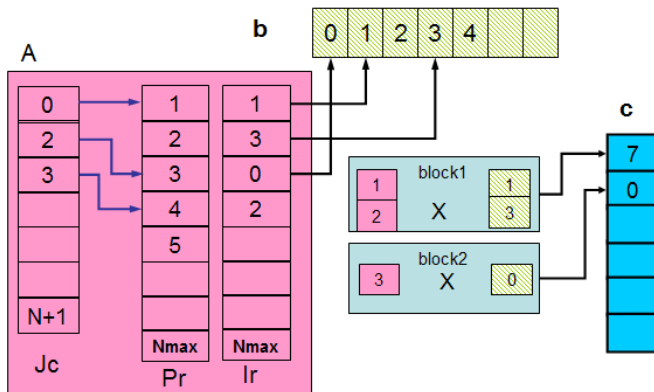


Fig. 3: Sparse Matrix

Unsere CUDA-Implementierung verwendet zur Speicherung ein abgewandeltes Matlab-Format. Statt in Spaltenfolge speichern wir die Matrix in Zeilenfolge, um bei der Multiplikation mit einem Spaltenvektor direkt die Multiplikationsschleife „über die Zeile treiben“ zu können.

Fig. 4: Matrix-Vektorprodukt mit Sparsematrix: Sparsematrix A, Zeilenindex j_c , Nonzero-Elemente j_r , Spalteninformation I_r , Multiplikand b, Produkt c

4) *Löser Gauss*: Basis für unsere CUDA-Implementierung ist ein Algorithmus aus der Standardliteratur [4] mit Pivottisierung. Da Teile des Algorithmus (z.B. Rückwärtssubstitution, Maximumssuche bei der Pivottisierung) nur sequentiell ausgeführt werden können fehlt die volle Ausnutzung der Parallelität.

III. TYPISCHE PROBLEME BEI DER GPU-PROGRAMMIERUNG

Die besondere Architektur der GPU führt zu besonderen Problemen und Ansätzen zur Problemlösung.

A. Dreieckförmige Summation

Ein typisches Problem ist Blocksummation. Aus der Beschreibungen der Operationen Multiplikationen der Matrix mal Vektor und Sparsematrix mal Vektor beruhen obige Operationen auf Vektormultiplikationen, die schließlich ein Summierungsverfahren in jedem Block enthalten. Blocksummation in einzigen Thread ist nicht effizient. Die einführende Algorithmus: Dreieckförmige Summation lautet wie Fig.5. In erst Schritte werden $2n$ und $2n+1$ Elements des Produktvektors cs in jeweilig Threads summiert. In zweiter Schritte werden $4n$ und $4n+2$ Elements summiert. Bis $BlockSize/2$ Schritte erhält man endlich Ergebnisse.




Fig. 5: Dreieckförmige Summation. Von Oben nach Unten zeigt

Beispiel Code kann man in [5] finden.

B. Minimierung leer laufende Thread

In CUDA bearbeitet jeder Multiprozessor gleichzeitig mit 32 Threads [2], die allen zum selben Block gehören. Bei der Sparsematrix-Multiplikation sind viele Threads am leerlaufen. Um die Leerlaufenden Threads zu minimieren, müssen mehrere Punktprodukte in einem Block bearbeitet werden. Dazu verwendet man 2 dimensionierte Blocksize. Die Definition und Anwendung von 2-D Blocksize findet man in der Referenz[2] und [6].

C. Shared Memory

In der Grafikate ist der Zugriff auf den globalen Speicher langsamer als auf den On-Chip-Speicher. Wie Beispiele in [2] gezeigt, kann man mehrer mal verwendete Daten zunächst in shared Memory schreiben, dann für die entsprechenden Operationen benutzen. In der Multiplikation der Vollmatrize mal Vektor wird jede Vektorelement mehr mal gebraut. Nach Untersuchungen wählen wir 1-Dimensionblock, die 64 beträgt und jede Vektorelement 8 mal gebraucht in einem Block, d.h. in jedem Block 8 zerlegende Vektormultiplikation bearbeitet werden. Die Abb.6.(Vergleich von optimierte Vollmatrixmultiplikation mit C-Implementierung und alte GPU-Implementierung für $M*N$ Vollmatrix) zeigt die Laufzeitenunterschied von unterschiedlichen Implementierung. Die genauen Messungen stellen in TabelleII dar.

Die optimierte GPU-Implementierung ist immer schnelle als die CPU-Implementierung und die Alte. Für Matrix




Fig. 6: Vergleich von optimierte Vollmatrixmultiplikation mit C-Implementierung und alte GPU-Implementierung für $M * N$ Vollmatrix

TABLE II: Ausführungszeiten der Vollmatrix-Vektormultiplikation $A_{mn} \cdot b$

m	10^4	10^5	50000	10^3	5000
n	50	50	50	10^3	5000
CPU(ms)	1.56	15.94	80	3.44	87.9
old GPU/CPU	1.711	1.6348	1.62548	0.164	0.12854
GPU/CPU	0.133	0.0662	0.06204	0.0512	0.03438

5000x5000 kann die CUDA-Programm 30 mal schneller als CPU

D. Schwierigkeit bei der Synchronisation vom Blockübergreifen

Für große Vektormultiplikation müssen mehrere Blöcke verwendet werden. Das Endergebnis bekommt man durch die Blocksummation. Da wir keine Synchronisationsmaßnahme für Blocksummation haben, kann der Vektor nicht im selben Kernel bearbeitet werden. Die Möglichkeiten wären, entweder die Blocksummation in CPU bearbeitet wird, oder die Blocksummation in einem neuen Kernel bearbeitet wird.

E. Fehlersuche im laufenden Algorithmus

Für die automatisierte Fehlersuche im laufenden CUDA-Algorithmus per Soll-Ist-Vergleich sind die Operationen als Command-Muster [7], der IDR(s) als Template-Muster [7] ausgeführt. CPU- oder GPU-Implementierungen der Operationen können auf den Algorithmus aufkonfiguriert werden.

IV. TESTERGEBNISSE

A. sparsemul

Versuch der Vergleich von matlab, CPU- und GPU-Implementierung wird in Abb.7 und Tabelle III. ausgewiesen. Für 128-Diagonalmatrix kann CUDA-Implementierung gegen CPU zu Faktor 9 erreichen.

B. Skalarprodukt

Tabelle IV zeigt die Ausführungszeiten des Skalarproduktes in Abhängigkeit der Vektorgöße N , je für eine Host-CPU Implementierung im Vergleich zu einer GPU-Implementierung. In Abb. 8 ist an der Stelle $N = 8000$ der Schnittpunkt der Ausführungszeitgraphen zu sehen - für große N führt die GPU die Operation schneller aus.




Fig. 7: Vergleich der Sparsematrix-Vektormultiplikation von matlab, CPU- und GPU-Implementierung.

TABLE III: Ausführungszeiten der Sparsematrix-Vektormultiplikation in ms

Diagonalen	1	3	16	32	64	128
Matlab	0.219	0.241	0.878	1.129	2.898	4
CPU	0.036	0.059	0.279	0.535	1.126	2.399
GPU(1x16)	0.051	0.062	0.204	0.376	0.787	1.666
GPU(16x1)	0.143	0.145	0.147	0.212	0.347	0.612
GPU(16x16)	0.092	0.091	0.0932	0.119	0.174	0.281

C. Löser Gauß

Tabelle V zeigt daß die GPU-Implementierung des Gauß-Lösers langsamer läuft als die CPU-Implementierung. Viele Schritte des Gauß-Algorithmus können nur sequentiell ausgeführt werden. Im rein sequentiellen Betrieb (bspw. im substitute-Teil des Algorithmus) ist die langsamere Taktrate der CUDA-Karte der größte Einfluss auf das Verhältnis der Ausführungszeiten. Für den IDR(s) relevant sind die $N \in [3, 6]$

D. IDR(s) Gesamtalgorithmus

Testproblem für das Messen ist das LGS für ein 1D-Laplaceproblem mit Randwerten. Die Zeilenanzahl des Test-LGS wird N genannt.




Fig. 8: Skalarprodukt: Ausführungszeit in Abhängigkeit von der Problemgröße N , double precision, Tesla C1060

TABLE IV: Ausführungszeiten der Operation Skalarprodukt, gemessen auf Tesla C1060 in double precision

N	t _{CPU} /ms	t _{GPU} /ms	Speedup
1000	0.041344	0.006848	-
8000	0.044288	0.043040	1.0
10 ⁵	0.086080	0.551808	6.8
10 ⁶	0.332928	6.685600	20.2
10 ⁷	2.675264	67.924385	26.1

TABLE V: Ausführungszeiten der Operation Löser Gauß

N	t _{GPU} /ms	t _{CPU} /ms	Speedup
3	0.037280	0.003168	-
4	0.030752	0.003104	-
5	0.033824	0.003104	-
6	0.043776	0.003040	-


$$\begin{pmatrix} 2 & 0 & 0 & 0 & 0 \\ 0 & 2 & -1 & 0 & 0 \\ 0 & -1 & 2 & -1 & 0 \\ 0 & 0 & -1 & 2 & -1 \\ 0 & 0 & 0 & 0 & 2 \end{pmatrix} \cdot \vec{x} = \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \\ -1 \end{pmatrix}$$

1) *Konvergenzverhalten:* Der Ergebnisvektor \mathbf{x} wird mit Zufallswerten $x_n \in [-0.5, 0.5]$ vorbelegt. Pro Iterationsschritt i wird das Residuum $r_i = |\mathbf{A} \cdot \mathbf{x}_i - \mathbf{b}|$ aufgezeichnet und im Abb. 9 gegen i aufgetragen.

Zu diesem Testproblem ergibt sich bei hinreichend genauer Toleranz ϵ als Lösung für \mathbf{x} eine Gerade. (Abb. 10)

Der CUDA-IDR(s) führt zu einer Gerade als Lösung bei einer Genauigkeit von 10^{-8} für N bis zu $N = 20000$.

Für größere N wird keine Gerade mehr errechnet. Für Toleranzen kleiner als 10^{-8} konvergiert der CUDA-IDR(s) nicht mehr, nach Durchschreiten des lokalen Residuen-Minimums klingt das Residuum auf gegen Unendlich.

Fig. 9: Residuenverlauf des CUDA-IDR(4) bei $N = 20000$ und Toleranz $\epsilon = 10^{-8}$

2) *Zeitverhalten:* Zum Zeitpunkt der Niederschrift läuft der CUDA-IDR(s) langsamer als die Matlab-Implementierung bei gleicher Parametrisierung (Tabelle VI). Das Zusammenspiel der Operationen ist momentan abgestimmt auf „reines Funktionieren“ bzgl. des Konvergenzverlaufes, eine Zeitoptimierung des Gesamtalgorithmus fehlt.


Fig. 10: Lösung \mathbf{x} des CUDA-IDR(4) bei $N = 20000$ und Toleranz $\epsilon = 10^{-8}$

TABLE VI: Ausführungszeiten des IDR(4), gemessen je auf Matlab v.2009b und auf Tesla C1060 in double precision

N	t _{Matlab} /s	t _{GPU} /s
10000	64	137
20000	415	922

V. MÖGLICHKEITEN FÜR DIE WEITERE OPTIMIERUNG DER IDR(S)-IMPLEMENTIERUNG

- Spezialkernel die angepasst sind auf bestimmte Matrixgrößen, denn der optimale Kernel für $A_{Ns} \cdot B_{s1}$ muß anders implementiert werden als $A_{sN} \cdot B_{N1}$. Hier wählt das Operation-Command selbstständig den passenden Kernel in Abhängigkeit von s und N .
- Einfügen von Instrumentation-Code analog dem Tuning-Interface des Oracle-RDBMS [8]. Die Idee besteht darin automatisiert jene Operationen zu identifizieren die in Summe den größten Beitrag zur Gesamtlaufzeit beitragen. Das Codeskelett dieses Instrumentation-Codes wurde bereits erstellt, aber noch nicht im Gesamtsystem verbaut.

VI. ZUSAMMENFASSUNG

Der CUDA-IDR(s) liefert dieselben Ergebnisse wie die Matlab-Vorlage. Die Einzeloperationen laufen schneller als ihre CPU/Matlab-Entsprechungen, der CUDA-IDR(s) insgesamt ist noch nicht optimiert bzgl. des Zeitverhaltens.

REFERENCES

- [1] P. Sonneveld and M. B. van Gijzen, "IDR(s): a family of simple and fast algorithms for solving large nonsymmetric linear systems," *SIAM J. Sci. Comput.*, vol. 31, no. 2, pp. 1035–1062, 2008. [Online]. Available: http://ta.twi.tudelft.nl/nw/users/gijzen/idrs_siam.pdf
- [2] (2009) NVIDIA CUDA Programming Guide Version 2.3. Nvidia Corporation. [Online]. Available: http://www.nvidia.de/object/cuda_develop_emeai.html
- [3] (2009) Matlab data. The Math works. [Online]. Available: http://www.mathworks.com/access/helpdesk/help/techdoc/matlab_external/f21585.html
- [4] R. Sedgewick, *Algorithmen in C*. Addison-Wesley, 1992.
- [5] M. Harris. (2009) Optimizing Parallel Reduction in CUDA. Nvidia Corporation. [Online]. Available: http://developer.download.nvidia.com/compute/cuda/1_1/Website/projects/reduction/doc/reduction.pdf
- [6] (2009) NVIDIA CUDA C Programming Best Practices Guide. Nvidia Corporation. [Online]. Available: http://www.nvidia.de/object/cuda_develop_emeai.html

- [7] E. Gamma, R. Helm, R. E. Johnson, and J. Vlissides, *Design Patterns. Elements of Reusable Object-Oriented Software*. Addison-Wesley, 1995.
- [8] M. Norgaard, “You probably don’t tune right,” in *Oracle Insights: Tales of the Oak Table*. New York: Apress, 2004, ch. 2, pp. 71–94.